



Tecnológico de Monterrey

Inteligencia artificial avanzada para la ciencia de datos 2

Gpo 501

Docentes

Dr. Benjamín Valdés Aguirre

Ma. Eduardo Daniel Juárez Pineda

Dr. Ismael Solis Moreno

Dr. José Antonio Cantoral Ceballos

Dr. Carlos Alberto Dorantes Dosamantes

Integrantes

Carlos Rodrigo Salguero Alcántara	A00833341
Diego Perdomo Salcedo	A01709150
Dafne Fernández Hernández	A01369230
José Emiliano Riosmena Castañón	A01704245
Luis Arturo Rendón Iñarritu	A01703572

1.0 Introducción	3
1.1 Propósito	3
2.0 Diseño de pruebas	3
2.1 División del Dataset	3
3.0 Problema, técnicas de modelado, supuestos	4
3.1 Técnica utilizada	5
3.2 Razonamiento	5
3.3 Consideraciones de usar otras tecnicas	5
3.4 Supuestos:	6
4.0 Modelado	7
4.1 Descripción/Arquitectura del modelo	7
4.2 Capa de Aumentación de Datos	7
4.2.1 Modelo Diurno	7
4.2.2 Modelo Nocturno	7
4.4 Pipeline de procesamiento	8
4.5 Hiperparámetros	8
5.0 Resultados del Modelo	9
5.1 Rendimiento Diurno	9
5.1.1 Resultados de Entrenamiento	9
5.1.2 Métricas de rendimiento	9
5.1.3 Comportamiento de la pérdida	9
5.1.4 Resultados en pruebas	10
5.1.5 Diagnóstico	10
5.2 Rendimiento Nocturno	11
5.2.1 Resultados de Entrenamiento	11
5.2.2 Métricas de rendimiento	11
5.2.3 Comportamiento de la Pérdida	11
5.2.4 Pruebas	12
4.2.5 Diagnóstico	12
6.0 Evaluar los Resultados	12
6.1 Modelo Diurno	12
6.1.1 Objetivos cumplidos	12
6.1.2 Complejidad	12
6.1.3 Características del Modelo	13
6.2 Modelo Nocturno	13
6.2.1 Objetivos cumplidos	13
6.2.2 Complejidad	13
❖ DenseNet169 posiblemente sobredimensionado	13
❖ Balance entre capacidad y generalización subóptimo	13
6.2.3 Características del Modelo	13

1.0 Introducción

Este documento describe la segunda iteración de la fase de modelado, donde se implementó una arquitectura DenseNet169 y se usó dataset generado en la segunda iteración de la preparación de datos. Este dataset tuvo un incremento en la cantidad de imágenes (aproximadamente 16,000 totales) basada en las condiciones de iluminación y el número de vacas por imagen comparándolo con los 8000 imágenes originales que teníamos.

1.1 Propósito

El propósito principal de este documento es establecer y documentar el proceso de selección, implementación y evaluación de técnicas de modelado para lograr una mejor detección y conteo vacas que el modelo anterior.

Este documento sirve como guía técnica y referencia para el equipo de desarrollo, stakeholders y futuros mantenedores del sistema, asegurando la transparencia en el proceso de desarrollo y facilitando la comprensión de las decisiones técnicas tomadas durante el proyecto.

2.0 Diseño de pruebas

Para asegurar una evaluación adecuada del modelo referente al objetivo de minería de datos, se ha implementado un el mismo diseño de pruebas que la iteración de modelado pasada.

2.1 División del Dataset

Generamos un script que hace una división estratificada del conjunto de datos en tres subconjuntos.

- ❖ Entrenamiento (training, 75%): un aproximado de 6,000 imágenes por condición de iluminación
- ❖ Validación (validation, 15%): un aproximado de 1,200 imágenes por condición de iluminación
- ❖ Pruebas (test, 10%): un aproximado de 800 imágenes por condición de iluminación

El programa mantiene la distribución proporcional de las categorías en cada subconjunto, lo que significa que conserva la representación relativa de cada clase en los tres

splits. La división se realiza de manera aleatoria y procesa los archivos en paralelo utilizando múltiples hilos para mejorar el rendimiento. Los datos divididos se guardan en directorios separados manteniendo la estructura original de las categorías.

2.2 Validación del diseño de pruebas con objetivos de minería de datos

Esta estructura de división nos permite validar efectivamente nuestro objetivo principal de minería de datos:

Objetivo de Minería de datos:

- ❖ Determinar la cantidad de vacas en cada imagen en cualquier condición.
 - Un modelo para condiciones diurnas con un 80% de precisión.
 - Un modelo para condiciones nocturnas con un 50% de precisión.

El diseño de pruebas actual, con su distribución equilibrada y volumen expandido de datos, nos permite:

- ❖ Evaluar el rendimiento del modelo en ambas condiciones de iluminación
- ❖ Validar el cumplimiento de los umbrales de precisión establecidos
- ❖ Asegurar la generalización del modelo a través de un conjunto de pruebas representativo

Esta estructura mejorada de validación, junto con el mayor volumen de datos, proporciona una base más sólida para evaluar el rendimiento del modelo.

3.0 Problema, técnicas de modelado, supuestos

Nuestro problema se centra en la clasificación y detección de vacas en imágenes bajo diversas condiciones de iluminación. En esta sección se detallan las técnicas de modelado consideradas y la solución implementada para la segunda iteración del proyecto.

Las técnicas principales consideradas incluyen:

- Redes neuronales convolucionales (CNN)
- Arquitecturas densamente conectadas (DenseNet)
- MobileNet
- EfficientNet

- ResNet y sus variantes

3.1 Técnica utilizada

Para esta iteración del proyecto, implementamos una solución basada en **DenseNet169**. Esta es una arquitectura de red neuronal convolucional que se caracteriza por sus conexiones densas, donde cada capa está conectada directamente con todas las capas posteriores dentro de un bloque denso. Esta estructura de conectividad permite un mejor flujo de información y gradientes a través de la red, facilitando el entrenamiento y reduciendo el número total de parámetros. A diferencia de las arquitecturas tradicionales, DenseNet reutiliza características mediante la concatenación directa, en lugar de suma, lo que permite un aprendizaje más eficiente y una mejor propagación de características a través de la red.

3.2 Razonamiento

La elección de DenseNet169 se fundamenta en varias ventajas clave:

1. **Eficiencia en la propagación de características:**
 - Conexiones densas que mejoran el flujo de información
 - Mejor reuso de características aprendidas
 - Menor número de parámetros para entrenar
2. **Robustez ante condiciones variables:**
 - Mejor manejo de características en diferentes niveles de abstracción
 - Mayor capacidad para aprender patrones complejos
 - Efectividad probada en tareas de clasificación visual

3.3 Consideraciones de usar otras técnicas

Las demás arquitecturas fueron descartadas por las siguientes razones:

1. **CNNs básicas:**
 - Menor capacidad de reutilización de características
 - Dificultad para manejar gradientes desvanecientes
 - Requieren más parámetros para lograr resultados similares
2. **MobileNet:**
 - Aunque eficiente, sacrifica demasiada precisión
 - Menor capacidad para características complejas
 - No óptima para condiciones de iluminación variable

3. EfficientNet:

- Mayor complejidad de implementación
- Requiere más recursos de computación
- Beneficios no justifican la complejidad adicional

4. ResNet:

- Conexiones residuales menos efectivas que las densas
- Mayor número de parámetros para resultados similares
- Menor eficiencia en la reutilización de características

La elección de DenseNet169, complementada con un pipeline de procesamiento robusto y técnicas de aumentación de datos específicas, representa una solución optimizada que balancea eficiencia computacional, precisión y capacidad de generalización para nuestro caso de uso específico.

3.4 Supuestos:

Supuestos sobre el Entorno:

- ❖ Las condiciones de iluminación permiten distinguir objetos del fondo.
- ❖ No hay factores ambientales extremos (niebla densa).
- ❖ La distancia entre la cámara y los objetos está dentro del rango de entrenamiento.
- ❖ El ángulo de visión es similar al de las imágenes de entrenamiento.

Supuestos sobre los Datos de Entrada:

- ❖ Las imágenes de entrada tienen una resolución mínima suficiente para distinguir vacas (al menos 640x640 píxeles).
- ❖ Los objetos a detectar (vacas) ocupan al menos un 5% del área total de la imagen.
- ❖ Las imágenes son a color (3 canales RGB).

Supuestos sobre los Objetos:

- ❖ Las vacas aparecen en posiciones naturales (de pie, pastando, caminando).
- ❖ Los objetos son distinguibles del fondo.

Supuestos sobre las Condiciones de Operación:

- ❖ La Raspberry Pi opera dentro de su rango de temperatura normal.
- ❖ Hay suficiente memoria disponible para el procesamiento.

- ❖ La fuente de alimentación es estable y suficiente.

4.0 Modelado

En esta sección se detallarán las características específicas del modelo implementado, incluyendo su funcionamiento, parámetros, comportamiento y limitaciones.

4.1 Descripción/Arquitectura del modelo

La arquitectura DenseNet169 representa una evolución significativa en el diseño de redes neuronales, caracterizándose por sus conexiones densas y patrones de conectividad eficientes. Configurada con un tamaño de entrada de 224x224x3, esta implementación aprovecha el pre-entrenamiento en ImageNet y utiliza una estrategia de fine-tuning específica, donde se mantienen congeladas las primeras 480 capas para preservar las características básicas aprendidas, mientras se permite el ajuste de las capas superiores para adaptarse a nuestro problema específico. Esta estructura de capas densamente conectadas permite una reutilización eficiente de características a través de la red, mientras que la estrategia de congelamiento y fine-tuning facilita la adaptación del modelo a nuestro dominio específico de detección de vacas sin perder las capacidades fundamentales de extracción de características desarrolladas durante el pre-entrenamiento.

4.2 Capa de Aumentación de Datos

4.2.1 Modelo Diurno

4.2.2 Modelo Nocturno

Aumentación	Valor	Probabilidad
Normalización	0.1	100%
Brillo	+ 0.2	80%
Contraste (factor)	1.2	80%
Volteo horizontal		0.5%

Ruido gaussiano	mu de 0, omega de 0.01	0.30%
-----------------	------------------------	-------

4.4 Pipeline de procesamiento

1. Capa de aumentación de datos
2. Ruido gaussiano
3. Rescalado (-1. 1)
4. DenseNet169
5. Global Average Pooling
6. Capa densa final (activación de softmax)

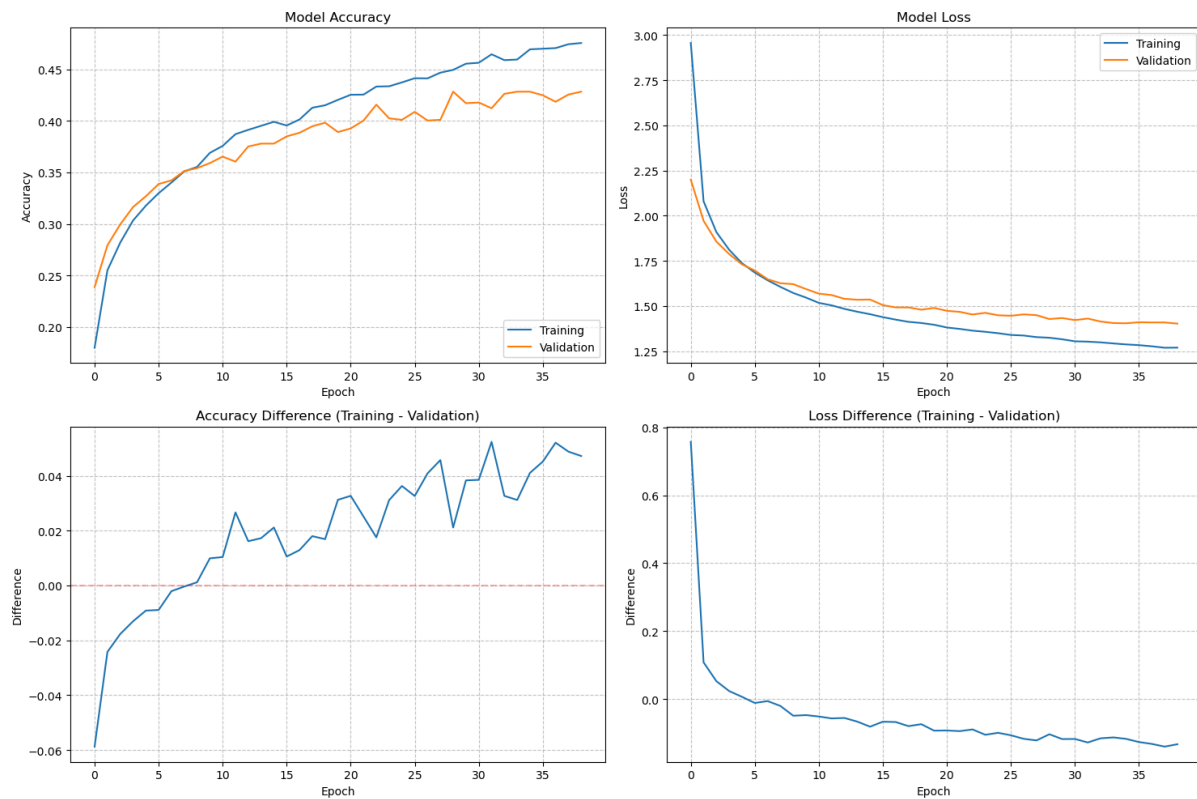
4.5 Hiperparámetros

- ❖ Learning rate: $5e-4$
- ❖ Weight decay: 0.01
- ❖ Dropout rate: 0.3
- ❖ Batch size: 32
- ❖ Épocas: 30
- ❖ Optimizados: AdamW

5.0 Resultados del Modelo

5.1 Rendimiento Diurno

5.1.1 Resultados de Entrenamiento



5.1.2 Métricas de rendimiento

❖ Entrenamiento

- Inicia en una precisión aproximada del 20%
- Incrementa constantemente hasta un aproximado de 47%
- Estabilización en la época 30

❖ Validación

- Fluctuación inicial entre 18% a 35%
- Estabilización aproximada de 42%
- Brecha creciente con el entrenamiento

5.1.3 Comportamiento de la pérdida

❖ Entrenamiento

- Disminución pronunciada inicial desde 3.0

- Convergencia cerca de 1.25
- ❖ Validación
 - Inicio en 2.2
 - Disminución gradual
 - Estabilización aproximada en 1.4

5.1.4 Resultados en pruebas

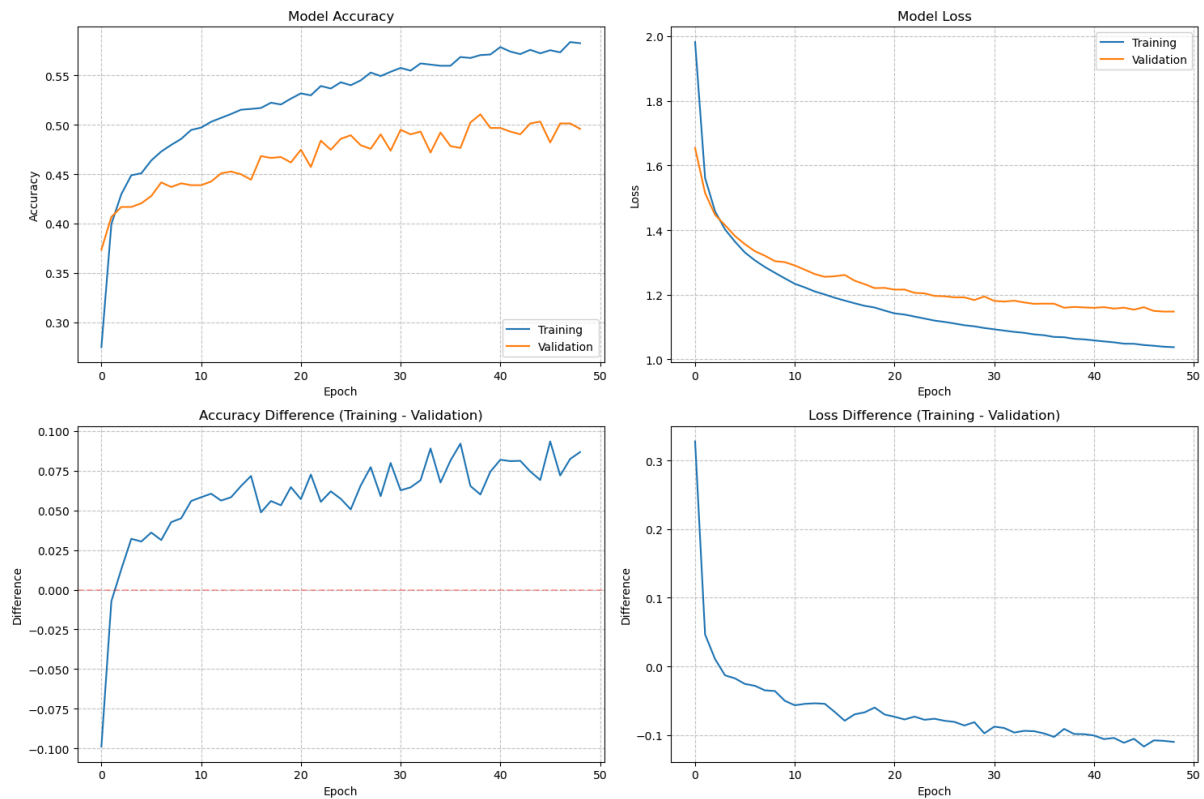
El modelo obtuvo una precisión de 43% en el subconjunto de datos destinado para pruebas.

5.1.5 Diagnóstico

- ❖ Sobreajuste moderado
 - Brecha creciente entre la precisión de entrenamiento y validación
 - Diferencia final de aproximadamente 5%
- ❖ Estabilidad relativa
 - Tendencias consistentes en las métricas
 - Divergencia gradual pero constante entre entrenamiento y validación
 - Gap final en pérdida de aproximadamente de 0.15.

5.2 Rendimiento Nocturno

5.2.1 Resultados de Entrenamiento



5.2.2 Métricas de rendimiento

❖ Entrenamiento

- Inicio: 45% de precisión
- Incremento constante hasta un aproximado de 60%
- Estabilización en la época 25

❖ Validación

- Fluctuación inicial: 37% a 43%
- Estabilización a 50%
- Brecha significativa con el entrenamiento

5.2.3 Comportamiento de la Pérdida

❖ Entrenamiento

- Disminución constante
- Convergencia cerca de 0

❖ Validación

- Pico en época 5
- Fluctuaciones importantes
- Estabilización aproximada a la mitad de la época 2

5.2.4 Pruebas

El modelo obtuvo una precisión de 49% en el subconjunto de datos destinado para pruebas.

4.2.5 Diagnóstico

- ❖ Sobreajuste significativo
 - Alta brecha entre la precisión de entrenamiento y validación
 - Pobre generación
- ❖ Inestabilidad en validación
 - Fluctuaciones en las métricas
 - Variabilidad en rendimiento

5.3 Limitaciones y Consideraciones

Categoría	Limitación	Justificación
Precisión Diurna	Rendimiento subóptimo	Precisión de prueba del 43%, con estabilización en validación al 42%
Precisión Nocturna	Variabilidad en rendimiento	Precisión de prueba del 49%, con fluctuaciones significativas en validación
Sobreajuste	Brecha entre métricas	Diferencia del 5% en modo diurno y mayor brecha en nocturno
Estabilidad	Fluctuaciones en validación	Variaciones importantes especialmente en modo nocturno
Convergencia	Comportamiento inconsistente	Pérdida diurna estable en 1.4, nocturna con picos y fluctuaciones
Generalización	Capacidad limitada	Evidencia de pobre generalización, especialmente en condiciones nocturnas

6.0 Evaluar los Resultados

Los modelos especializados por condiciones de iluminación alcanzaron la precisión de:

- ❖ Modelo diurno:
 - Entrenamiento: 47%
 - Validación: 42%
 - Pruebas: 43%
- ❖ Modelo nocturno: 36.22%
 - Entrenamiento: 60%
 - Validación: 50%
 - Pruebas: 49%

6.1 Validación de Objetivos

NO LOGRAMOS EL OBJETIVO

Objetivo de Minería de Datos

- ❖ Determinar la cantidad de vacas en cada imagen en cualquier condición.
 - Un modelo para condiciones diurnas con un 80% de precisión.
 - Un modelo para condiciones nocturnas con un 50% de precisión.

En esta segunda iteración, el modelo continúa mostrando limitaciones significativas para alcanzar los objetivos establecidos de minería de datos. El modelo diurno solo alcanzó un 47% de precisión en entrenamiento y aproximadamente 42-43% en validación y pruebas, quedando muy por debajo del objetivo del 80%. Aunque el modelo nocturno logró superar el umbral del 50%, se observaron problemas de sobreajuste y generalización en ambos casos. El uso de DenseNet169 resultó posiblemente sobredimensionado para la tarea, y aunque mostró un aprendizaje estable y predecible, la capacidad limitada y la convergencia temprana sugieren la necesidad de reconsiderar la arquitectura del modelo. Si bien se observaron algunas mejoras respecto a la primera iteración, particularmente en el modelo nocturno, los resultados generales indican que aún no se ha encontrado una solución óptima para cumplir con los objetivos establecidos del proyecto.

6.2 Siguiendo pasos

Analizando nuestros resultados vemos que con las imágenes que agregamos y este modelo logramos alcanzar uno de los dos criterios de éxito para cumplir con el objetivo.

Evaluando esto continuaremos con otra iteración de modelado para poder alcanzar el siguiente criterio y cumplir con el objetivo de minería de datos.