



Tecnológico de Monterrey

Inteligencia artificial avanzada para la ciencia de datos 2

Gpo 501

Docentes

Dr. Benjamín Valdés Aguirre

Ma. Eduardo Daniel Juárez Pineda

Dr. Ismael Solis Moreno

Dr. José Antonio Cantoral Ceballos

Dr. Carlos Alberto Dorantes Dosamantes

Integrantes

Carlos Rodrigo Salguero Alcántara	A00833341
Diego Perdomo Salcedo	A01709150
Dafne Fernández Hernández	A01369230
José Emiliano Riosmena Castañón	A01704245
Luis Arturo Rendón Iñarritu	A01703572

Querétaro, Querétaro

1.0 Introducción	3
1.1 Propósito	3
2.0 Análisis Comparativo de Modelo y Recursos	3
2.1 Comparación de Métricas Clave	3
2.1.1 Métricas Específicas de YOLO	4
3.0 Evaluación de los resultados	4
3.1 Cumplimiento con el objetivo de negocio	4
3.2 Modelos aprobados	5
3.1.1 ResNet50v2	5
3.1.2 YOLOv8x	5
3.1.3 YOLOv9c	6
3.3 Deficiencias Identificadas	6
3.4 Resultados	7
3.4.1 Patrones Diarios	7
3.4.2 Casos Específicos	8
3.4.3 Análisis Semanal	9
4.0 Proceso de revisión	10
4.1 Visión general del proceso de minería de datos	10
4.2 Retrospectiva	11
4.2.1 Mejoras, fallas, pasos engañosos del proceso	12
5.0 Lista de posibles acciones	14
6.0 Decisión	15
Anexos	16
Anexo A	16
Complejidad Computacional	16

1.0 Introducción

Este documento presenta la evaluación integral del proyecto.

1.1 Propósito

El propósito de este documento es:

- ❖ Evaluar el cumplimiento de objetivos de negocio y de minería de datos
- ❖ Documentar el rendimiento y eficacia de las soluciones implementadas
- ❖ Los modelos aprobados
- ❖ Identificar áreas de deficiencia
- ❖ Lista de posibles acciones
- ❖ Decisión tomada

2.0 Análisis Comparativo de Modelo y Recursos

(El F1 y Precisión de los faltantes se actualizaran adecuadamente para la entrega final, esto porque los estamos volviendo a correr para sacar las métricas correctas)

2.1 Comparación de Métricas Clave

			F1		Precisión	
Tipo	Arquitectura del Modelo	Dataset (número de imágenes)	Val	Test	Val	Test
Día	ResNet50V2	4000	0.1814	0.1815	35.88%	30.55%
Noche	ResNet50V2	3347	0.2293	0.2295	39.58%	39.57%
Día	DenseNet169	8000	0.2704	0.2705	40.30%	41.89%
Noche	DenseNet169	8000	0.3100	0.3100	51.06%	51.66%
Día	XGBoost +	8000	0.2630	0.2595	52.09%	27.23%

	ResNet50V2					
Día	MobileNetV3Large ¹	8000	0.5878	0.474	48.63%	50.3%
General	YOLOv8x	8000	0.93	0.93	92%	93%
General	YOLOv9c	8000	0.93	0.93	93%	93%

2.1.1 Métricas Específicas de YOLO

Modelo	mAP50 (B)	mAP50-95 (B)
YOLOv8x	0.95	0.80
YOLOv9c	0.96	0.815

3.0 Evaluación de los resultados

En esta sección se evaluará el objetivo de negocio y los modelos aprobados que cumplen

3.1 Cumplimiento con el objetivo de negocio

Para determinar si hemos cumplido con el objetivo de negocio debemos de evaluar si logramos el criterio de éxito que habíamos definido.

Objetivo de Negocio

- ❖ Identificar el número de vacas en cada fila en un periodo de tiempo determinado.
 - Determinar con alta precisión la cantidad de vacas en una imagen. Arturo o Ivo determinarán si la precisión es satisfactoria.

¹ Los valores presentados para este modelo corresponden a solo 7 clases de 12.

Tras mostrarle los resultados de los modelos al socio formador determinó que la precisión era satisfactoria. Con esto podemos declarar que cumplimos con nuestro objetivo de negocio. Para comprobar la palabra del socioformador firmó un documento que declara la validación de este objetivo el cual se encuentra en la siguiente liga: ■ Validación del Objetivo De Negocio.pdf

<https://github.com/salgue441/cow-project/blob/main/docs/Validaci%C3%B3n%20del%20Objetivo%20De%20Negocio.pdf>

3.2 Modelos aprobados

Tras evaluar los resultados de los diferentes modelos tenemos un total de 3 modelos que pudieron cumplir con 1 o 2 criterios de éxito en el objetivo de minería de datos.

Objetivo de Minería de Datos:

- ❖ Determinar la cantidad de vacas en cada imagen en cualquier condición.
 - Un modelo para condiciones diurnas con un 80% de precisión.
 - Un modelo para condiciones nocturnas con un 50% de precisión.

3.1.1 ResNet50v2

El modelo ResNet50V2 logró un cumplimiento parcial del objetivo de minería de datos. Los resultados muestran que mientras el modelo alcanzó una precisión de sólo 30% en condiciones diurnas (muy por debajo del requisito del 80%), sí logró superar el umbral establecido para condiciones nocturnas con una precisión del 51.49% en el conjunto de pruebas, superando ligeramente el criterio mínimo del 50%. Esta distinción en el rendimiento demuestra que, aunque el modelo no fue exitoso como solución integral, sí demostró capacidad suficiente para el escenario nocturno. Entonces es aprobado como un modelo que se pudiera utilizar solamente para bajas condiciones de iluminación.

3.1.2 YOLOv8x

El modelo YOLOv8x demostró un rendimiento excepcional al lograr cumplir con el objetivo de minería de datos, que requería determinar la cantidad de vacas en cada imagen bajo cualquier condición. Los resultados obtenidos fueron notables:

- ❖ mAP50 de 0.95 (95% de precisión)

❖ mAP50-95 de 0.80 (80% de precisión promedio)

Al mantener una precisión promedio del 80% (mAP50-95) en todas las condiciones, el modelo logró superar ambos criterios de éxito simultáneamente: el requisito del 80% para condiciones diurnas y el 50% para condiciones nocturnas.

3.1.3 YOLOv9c

El modelo YOLOv9c superó los resultados del modelo anterior, demostrando un rendimiento superior al cumplir con el objetivo de minería de datos.

- mAP50 de 0.96 (96% de precisión)
- mAP50-95 de 0.815 (81.5% de precisión promedio)

El modelo superó ambos criterios de éxito establecidos. Al mantener una precisión promedio de 81.5% en todas las condiciones, YOLOv9c excedió tanto el requisito del 80% para condiciones diurnas como el 50% para condiciones nocturnas. Este rendimiento excepcional demuestra que incluso en los escenarios más desafiantes, el modelo mantuvo una precisión significativamente superior al umbral mínimo requerido para condiciones nocturnas, mientras que en condiciones óptimas alcanzó una precisión del 96%.


3.3 Deficiencias Identificadas

Tuvimos dos modelos que tuvieron resultados excepcionales al poder cumplir con ambos criterios de éxito del objetivo de minería de datos. A pesar de que estos modelos (YOLOv8x y YOLOv9c) tuvieron una precisión mayor a 80% con un dataset que incluía imágenes de ambos niveles de iluminación, es importante notar que estos modelos no operan de manera óptima en condiciones nocturnas debido a limitaciones técnicas en la captura de imágenes. La calidad reducida de las imágenes nocturnas, caracterizada por iluminación insuficiente, mayor ruido digital y contrastes menos definidos, afecta la capacidad del modelo para mantener su máximo rendimiento. Si bien los modelos superan el umbral mínimo requerido para condiciones nocturnas (50%), su rendimiento podría mejorarse significativamente mediante la implementación de iluminación adicional en las áreas de captura, lo cual permitiría obtener imágenes de mejor calidad y, consecuentemente, una detección más precisa durante la noche. Para ser transparentes con nuestros clientes se presentó y firmó un documento hablando de este tema en el cual dicta que está consciente de estas deficiencias.

<https://github.com/salgue441/cow-project/blob/main/docs/Declaraci%C3%B3n%20T%C3%A9cnica%20sobre%20las%20Limitaciones%20del%20Modelo%20en%20Condiciones%20Nocturnas.pdf>

3.4 Resultados

Utilizando el modelo de YOLOv9c pudimos obtener resultados tras un análisis de los patrones de comportamiento de las vacas, se identificaron varios hallazgos significativos:



3.4.1 Patrones Diarios


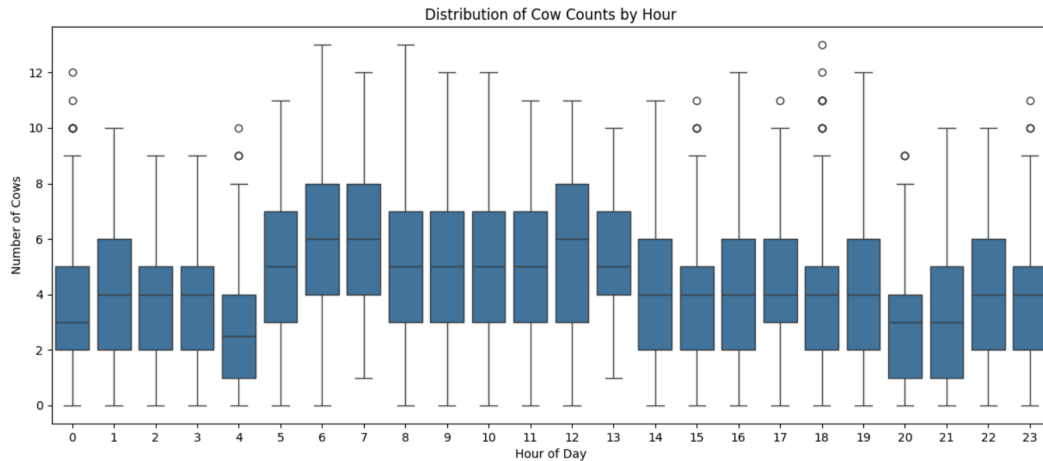
Se observó un patrón consistente en la cantidad de vacas formadas a lo largo del día:

1. **Punto Mínimo Matutino:** A las 4:00 AM se registra una caída significativa, llegando a un promedio de solo una vaca formada.
2. **Incremento Matutino:** Entre las 4:00 AM y 7:00 AM se observa un incremento notable:
 - Duración: 3 horas

- Resultado: Alcanza un promedio de 7 vacas formadas a las 7:00 AM

3. Descenso Gradual: Durante el resto del día se presenta una disminución progresiva:

- Culmina en un segundo punto mínimo a las 8:00 PM
- Promedio de dos vacas formadas en este horario



3.4.2 Casos Específicos


Se identificaron días que ejemplifican claramente estos patrones:

2024-05-16:

- Mínimos: 0 vacas entre 1:00 AM y 3:00 AM
- Máximo: 12 vacas a las 8:00 AM
- Descenso: 3 vacas a las 8:00 PM

2024-05-06:

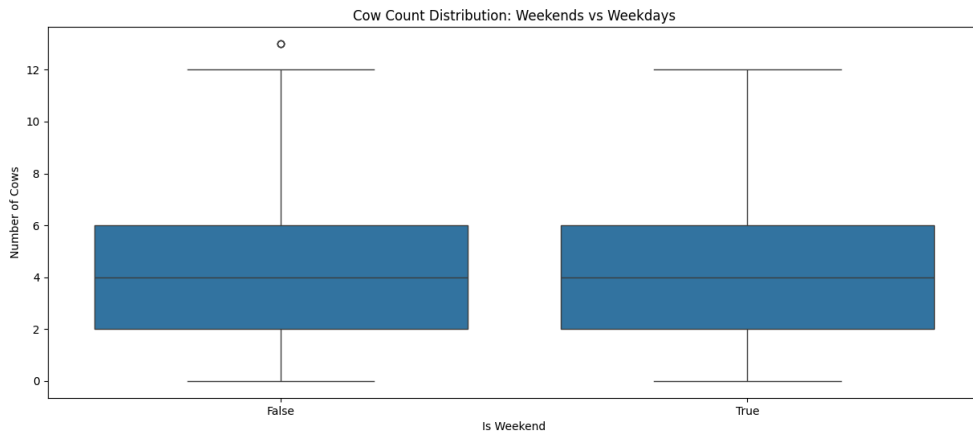
- Mínimo: 2 vacas durante la madrugada
- Máximo: 10 vacas a las 9:00 AM
- Descenso: 3 vacas a las 8:00 PM



3.4.3 Análisis Semanal

Se realizó un análisis comparativo entre días de la semana y fines de semana:

1. **Comparación Diaria:** No se encontraron diferencias significativas en los patrones entre los diferentes días de la semana.
2. **Entre Semana vs. Fin de Semana:**
 - La cantidad promedio de vacas formadas es prácticamente idéntica
 - No se observan variaciones significativas en los patrones de comportamiento
 - Los ciclos se mantienen consistentes independientemente del día de la semana



Esta consistencia en los patrones, independiente del día de la semana, sugiere que el comportamiento de las vacas responde principalmente a factores circadianos naturales más que a variables externas relacionadas con la actividad humana o el manejo del ganado.

4.0 Proceso de revisión

En esta sección se mencionara como llevamos a cabo el proyecto, las actividades de cada fase, y una sección de retrospectiva para evaluar qué hicimos mal y que pudimos haber hecho mejor.

4.1 Visión general del proceso de minería de datos

Para realizar este proyecto se siguió las fases de CRISP-DM, adaptándolas a las necesidades específicas del proyecto de detección y conteo de vacas. A continuación, una visión general del proceso :

1. Comprensión del negocio

Actividades realizadas:

- ❖ Reuniones con CAETEC para entender el contexto operativo
- ❖ Definición de objetivos de negocio y minería de datos
- ❖ Establecimiento de criterios de éxito medibles
- ❖ Evaluación de recursos disponibles

- ❖ Desarrollo de plan de proyecto

2. Comprensión de datos

Actividades realizadas:

- ❖ Adquisición de los datos
- ❖ Análisis exploratorio usando Tableau
- ❖ Evaluación de calidad de imágenes
- ❖ Análisis de distribución de luminosidad
- ❖ Caracterización de condiciones día/noche

3. Preparación de datos

Actividades realizadas:

- ❖ Clasificación de imágenes
- ❖ Establecimiento de criterios de etiquetado
- ❖ División en conjuntos de entrenamiento/validación
- ❖ Organización de estructura de almacenamiento
- ❖ Generar el dataset

4. Modelado

Actividades realizadas:

- Experimentación con múltiples arquitecturas
- Implementación de técnicas de transfer learning
- Optimización de hiperparámetros
- Evaluación comparativa de modelos
- Refinamiento iterativo

4.2 Retrospectiva

En esta sección se reflexionó sobre si verdaderamente cada fase fue necesaria.

1. Entendimiento del negocio

Esta fase fue absolutamente necesaria para el proceso. Sin esta fase no habiéramos podido definir adecuadamente el objetivo del proyecto, ya que requerimos comprender la necesidad del cliente para poder plantearnos una meta clara que alcanzar. Sin este entendimiento fundamental, el proyecto habría carecido de dirección y propósito.

2. Entendimiento de los datos

Esta fase también resultó significativa, ya que nos permitió familiarizarnos con los datos disponibles. Sin esta fase, habríamos estado trabajando a ciegas, sin comprender las características y particularidades de nuestro material de trabajo. La omisión de esta fase habría llevado a decisiones mal informadas en etapas posteriores.

3. Preparación de los datos

La preparación de los datos fue una fase crítica e imposible de ignorar. Sin esta fase, el proyecto no habría tenido un dataset estructurado con el cual trabajar, haciendo imposible el desarrollo y entrenamiento de modelos efectivos.

4. Modelado

La fase de modelado representa el núcleo técnico del proyecto. Sin esta fase, habría sido imposible alcanzar el objetivo de minería de datos, y por consecuencia, el objetivo de negocio. Esta fase fue esencial para transformar los datos preparados en conocimiento accionable.

4.2.1 Mejoras, fallas, pasos engañosos del proceso

Todos los pasos del proceso son importantes para poder dar resultados. A pesar de que todos se ejecutaron de forma correcta hubieron fallos y caminos inesperados a lo largo del proceso. En esta sección se destacan esos fracasos, su causa raíz, y como lo mejoramos y lo pudimos haber hecho mejor.

4.2.1.1 Plan de Proyecto

Fallo:

Al iniciar la fase de business understanding tuvimos muchos fallos que se pudieron haber evitado. Principalmente uno de los problemas que tuvimos era que no teníamos claro que había que hacer. Pasaban los días y no teníamos una dirección clara de las actividades que debíamos de hacer para sacar el proyecto adelante.

Causa raíz:

Esto ocurrió porque no definimos un plan de trabajo apto para el proyecto. Lo único que habíamos definido eran las fechas aproximadas que iba a tomarnos hacer cada fase del proceso. Al no definir un plan no teníamos definido que debía de hacer cada persona en cada fase causando un retraso más grande de lo esperado. Entonces a pesar de que luego si lo hicimos, el daño ya estaba hecho.

Mejoras:

- ❖ Dedicar más tiempo a la fase inicial de planificación
- ❖ No asumir que el equipo entiende implícitamente sus responsabilidades
- ❖ Crear documentación clara y accesible para todo el equipo

4.2.1.2 Iteraciones

Camino inesperado:

Inicialmente pensamos que nos iba a tomar a lo mucho 2 iteraciones de preparación de datos y 2 de modelado. Por estas razones cuando se hizo el plan de trabajo no pensamos que estas dos fases nos iban a tomar más tiempo de lo presupuestado. Pero tuvimos un camino muy inesperado al terminar haciendo 3 fases de preparación de datos y 5 de modeling.

Causa raíz:

La causa de este camino que tomamos se debe a una mala preparación de los datos, y modelado. Nosotros mismos al clasificar las vacas se nos hacía exageradamente difícil determinar la cantidad, en especial las imágenes con muchas vacas y poca iluminación. Dividir el dataset en carpetas por cantidad de vacas y luego intentar con una red neuronal convolucional era soñar con lo imposible. Si las personas que clasificaron las imágenes de equivocaban un modelo tampoco iba

a poder aprender adecuadamente. Nos quedamos probando con más arquitecturas en lugar de cambiar el enfoque.

Mejoras:

- Investigar más papers sobre cómo otras personas han resuelto problemas similares
- Realizar un análisis de viabilidad técnica más profundo antes de elegir un enfoque
- Estar dispuesto a pivotar cuando un enfoque no funciona

5.0 Lista de posibles acciones

Al ver los resultados de los modelos aprobados podemos listar las posibles acciones que podemos realizar.

Acción	Razones a favor	Razones en contra
Considerando que hemos logrado el objetivo de negocio nuestra primera opción sería continuar con la fase de entrega con el modelo de YOLOv9c.	<ul style="list-style-type: none">- Este modelo logró cumplir con el objetivo de minería de datos y de negocio.- Considerando los recursos disponibles (el tiempo de los miembros del equipo), es una opción viable.	<ul style="list-style-type: none">- Aunque cumplió con los objetivos el modelo no opera muy bien de noche lo que significa en esas condiciones no es muy fiable.
Otra opción sería regresar a la fase de entendimiento del negocio y crear un nuevo proyecto.	<ul style="list-style-type: none">- Regresando al inicio es posible que descubramos nueva información que nos pudiera servir para hacer un proyecto/modelo que dé mejores resultados.	<ul style="list-style-type: none">- No tenemos el tiempo disponible para poder realizar esta acción.
Viendo que el modelo de YOLOv9c tiene un alto	<ul style="list-style-type: none">- Las vacas no son afectadas por la luz entonces puede llegar a dar	<ul style="list-style-type: none">- Sería requerido que nosotros o el caetec implemente algún tipo

rendimiento principalmente en el día, sería posible hacer pruebas con algun tipo de iluminación en la noche.	mejores resultados que los actuales.	de iluminación e igual se tuvieran que capturar más imagenes para poder tener un nuevo dataset, no hay tiempo ni presupuesto para poder hacer esto adecuadamente.
--	--------------------------------------	---

6.0 Decisión

Como equipo hemos tomado la decisión de continuar a la siguiente fase usando el modelo que obtuvo un mejor rendimiento, está siendo el YOLOv9c. Considerando que es el modelo que mayor precisión que tenemos es lo mejor que podemos entregar al cliente en la siguiente fase.

Anexos

Anexo A

Complejidad Computacional

Modelo	Parámetros	Capas
YOLOv8x	25.8 M	218
YOLOv9c	17.4 M	48
ResNet50V2`	23.5 M	50
DenseNet169	14.3 M	169
MobileNetV3Large	5.4 M	~160