



Tecnológico de Monterrey

Inteligencia artificial avanzada para la ciencia de datos 2

Gpo 501

Docentes

Dr. Benjamín Valdés Aguirre

Ma. Eduardo Daniel Juárez Pineda

Dr. Ismael Solis Moreno

Dr. José Antonio Cantoral Ceballos

Dr. Carlos Alberto Dorantes Dosamantes

Integrantes

Carlos Rodrigo Salguero Alcántara	A00833341
Diego Perdomo Salcedo	A01709150
Dafne Fernández Hernández	A01369230
José Emiliano Riosmena Castañón	A01704245
Luis Arturo Rendón Iñarritu	A01703572

Querétaro, Querétaro

1.0 Introducción	3
2.0 Objetivos	3
3.0 Modelo	3
3.1 Descripción General	3
3.2 Arquitectura Principal	4
1. Backbone (Red Troncal)	4
2. Neck (Cuello)	4
3. Head (Cabeza)	4
3.3 Proceso de Detección	4
1. Preprocesamiento	4
2. Forward Pass	4
3. Post Procesamiento	5
4.0 Resultados	5
4.1 Resultados Obtenidos	5
4.2 Hallazgos	6
4.3 Implicaciones para las Operaciones	7
4.4 Validación del objetivo	8
5.0 Descripción del proceso:	8
5.1 Fases del proyecto	8
5.2 Costos asociados al proyecto	10
5.3 Desviaciones del plan original.	10
5.4 Planes de implementación:	11
5.5 Recomendaciones para el futuro:	11

1.0 Introducción

Este reporte técnico presenta los resultados del proyecto para el CAETEC, enfocado en la detección y conteo automatizado de ganado bovino. Utilizando el modelo YOLOv9c de inteligencia artificial, hemos implementado una solución capaz de identificar y contar vacas en tiempo real bajo diversas condiciones de iluminación. A continuación, se detallan los objetivos alcanzados, el funcionamiento del modelo implementado y los resultados obtenidos, junto con un análisis de su impacto en las operaciones diarias de la granja.

2.0 Objetivos

Considerando el contexto del proyecto estos son los objetivos que se habían planteado alcanzar:

Objetivo de Negocio

- ❖ Identificar el número de vacas en cada fila en un periodo de tiempo determinado.
 - Determinar con alta precisión la cantidad de vacas en una imagen. Arturo o Ivo determinarán si la precisión es satisfactoria.

Objetivo de Minería de Datos

- ❖ Determinar la cantidad de vacas en cada imagen en cualquier condición.
 - Un modelo para condiciones diurnas con un 80% de precisión.
 - Un modelo para condiciones nocturnas con un 50% de precisión.

Teniendo en mente estos objetivos se explicará a detalle la herramienta utilizada para lograrlos.

3.0 Modelo

3.1 Descripción General

YOLOv9c representa la evolución más reciente de la familia de modelos YOLO, manteniendo los principios fundamentales de detección en una sola pasada mientras introduce mejoras significativas en eficiencia computacional y precisión. El modelo procesa imágenes completas en una sola pasada a través de su red neuronal, tratando la detección como un problema de regresión directa.

3.2 Arquitectura Principal

El modelo YOLOv9c mantiene una estructura tripartita similar a su predecesor, pero con optimizaciones significativas en cada componente:

1. Backbone (Red Troncal)

- Implementa una arquitectura CSPDarknet mejorada
- Incorpora conexiones Cross-Stage-Partial (CSP) optimizadas
- Mejora el flujo de información mientras reduce la complejidad computacional
- Mantiene la capacidad de extracción de características mientras optimiza el uso de recursos

2. Neck (Cuello)

- Utiliza una estructura PANet (Path Aggregation Network) refinada
- Implementa una jerarquía de características más eficiente
- Mejora la propagación de información entre niveles
- Optimiza la detección multi-escala con menor overhead computacional

3. Head (Cabeza)

- Sistema de predicción mejorado
- Genera bounding boxes y scores de confianza con mayor eficiencia
- Mantiene el enfoque anchor-free para las detecciones
- Implementa un sistema optimizado de decodificación de predicciones

3.3 Proceso de Detección

1. Preprocesamiento

- Redimensionamiento de imágenes a 640x640 píxeles
- Normalización optimizada de valores de píxeles
- Sistema mejorado de aumentación de datos durante el entrenamiento

2. Forward Pass

- Proceso optimizado de extracción de características
- Mejor integración entre los componentes backbone, neck y head

- Mayor eficiencia en la generación de predicciones

3. Post Procesamiento

- Sistema refinado de filtrado por umbral de confianza
- Non-Maximum Suppression (NMS) optimizado
- Generación más eficiente de predicciones finales

4.0 Resultados

Con el modelo anterior se obtuvieron los siguientes resultados y además pudimos validar el objetivo de minería de datos.

4.1 Resultados Obtenidos

- ❖ Precisión: 93%.

Los resultados obtenidos durante este proyecto demuestran un rendimiento excepcional del sistema de detección y conteo de ganado, alcanzando métricas que superan significativamente las expectativas iniciales. El modelo logró una precisión del 93%, lo que significa que cuando el sistema identifica una vaca en la imagen, esta identificación es correcta en la gran mayoría de los casos. Esta alta precisión es crucial para garantizar que los conteos proporcionados sean confiables y útiles para la toma de decisiones operativas.

- ❖ Recall: 94%.

Complementando esta precisión, el sistema alcanzó un recall del 94%, indicando una capacidad sobresaliente para detectar las vacas presentes en las imágenes. Este alto nivel de recall significa que el sistema raramente pasa por alto animales que deberían ser contados, proporcionando una visión completa y precisa del ganado presente en cualquier momento dado. La combinación de alta precisión y alto recall demuestra que el sistema no solo es preciso en sus detecciones, sino que también es exhaustivo en su capacidad de encontrar todos los animales presentes.

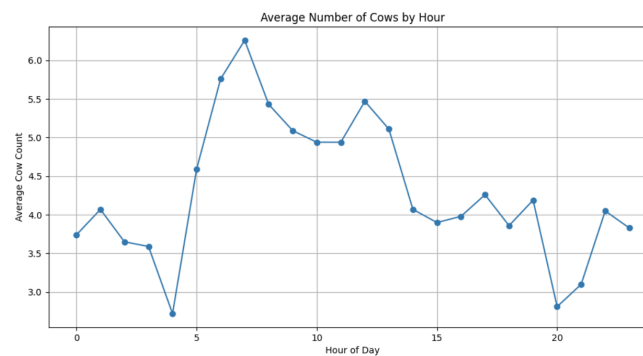
- ❖ Tiempo de procesamiento: 3.5 ms por imagen.

En términos de rendimiento operativo, el sistema procesa cada imagen en aproximadamente 3.5 milisegundos, lo que permite un monitoreo prácticamente en tiempo real. Esta velocidad de procesamiento es particularmente importante para mantener un

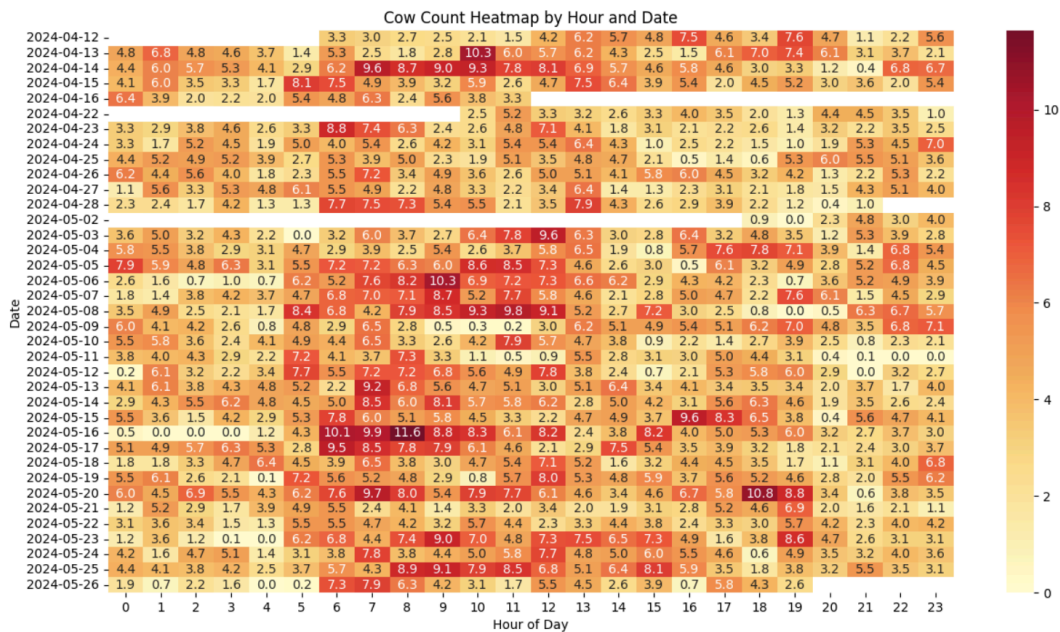
seguimiento continuo y efectivo del ganado, permitiendo respuestas rápidas a cualquier situación que requiera atención.

4.2 Hallazgos


El análisis de los datos recolectados ha revelado patrones importantes en el comportamiento del ganado. Uno de los descubrimientos más significativos es el aumento considerable en la cantidad de ganado formado para ordeño alrededor de las 7:00 AM en adelante.



También se identificaron períodos regulares de baja actividad, particularmente durante las primeras horas de la madrugada (alrededor de las 4:00 AM) y en la noche (cerca de las 8:00 PM), donde el conteo puede disminuir hasta registrar un solo animal. Estos patrones son consistentes y predecibles, lo que permitirá a los trabajadores observar porque disminuye la cantidad de vacas a esas horas.



Se buscaron variaciones en los patrones entre diferentes días de la semana. Sin embargo, los datos revelan que no existen diferencias significativas en el comportamiento del ganado entre los distintos días. Las variaciones observadas están más relacionadas con las horas del día que con el día específico de la semana, lo que sugiere que el comportamiento del ganado sigue un ritmo circadiano consistente independientemente del día.



4.3 Implicaciones para las Operaciones

La consistencia en los patrones identificados tiene importantes implicaciones para la gestión diaria de la granja. El conocimiento preciso de los momentos de mayor actividad, como el pico de las 7:00 AM, permite poder investigar porque picos como estos surgen a estas horas. De esta forma pueden usar este conocimiento para buscar formas de incrementar el flujo de producción cuando baja la actividad de las vacas. Otra opción también es que en los períodos de baja actividad identificados también pueden ser aprovechados estratégicamente para

realizar tareas de mantenimiento y otras actividades operativas que requieran menor presencia de ganado.

4.4 Validación del objetivo

Los objetivos de minería de datos establecidos inicialmente proponían alcanzar 80% de precisión para condiciones diurnas y 50% para nocturnas, metas que fueron superadas significativamente al desarrollar un modelo unificado que alcanzó 93% de precisión en todas las condiciones de iluminación. Este logro no sólo simplificó la implementación al evitar la necesidad de modelos separados para día y noche, sino que también demostró un rendimiento superior al requerido en ambas condiciones, validando así el cumplimiento del objetivo de minería de datos.

Respecto al objetivo de negocio, que buscaba determinar con alta precisión la cantidad de vacas en cada imagen, este fue validado exitosamente mediante la firma de un documento por parte del Socio Formador, quien expresó su satisfacción con el nivel de precisión alcanzado por el sistema. Esta validación formal confirma que el modelo cumple con las expectativas y requerimientos operativos establecidos para el proyecto.

<https://github.com/salgue441/cow-project/blob/main/docs/Validaci%C3%B3n%20del%20Objetivo%20De%20Negocio.pdf>

5.0 Descripción del proceso:

En esta sección se destaca el proceso que se llevó para abordar este proyecto, los costos, entre más

5.1 Fases del proyecto

Esto es una breve descripción del proceso que se llevó a cabo para realizar el proyecto de inicio a fin.

1. Comprensión del negocio

Actividades realizadas:

- ❖ Reuniones con CAETEC para entender el contexto operativo
- ❖ Definición de objetivos de negocio y minería de datos

- ❖ Establecimiento de criterios de éxito medibles
- ❖ Evaluación de recursos disponibles
- ❖ Desarrollo de plan de proyecto

2. Comprensión de datos

Actividades realizadas:

- ❖ Adquisición de los datos
- ❖ Análisis exploratorio usando Tableau
- ❖ Evaluación de calidad de imágenes
- ❖ Análisis de distribución de luminosidad
- ❖ Caracterización de condiciones día/noche

3. Preparación de datos

Actividades realizadas:

- ❖ Clasificación de imágenes
- ❖ Establecimiento de criterios de etiquetado
- ❖ División en conjuntos de entrenamiento/validación
- ❖ Organización de estructura de almacenamiento
- ❖ Generar el dataset

4. Modelado

Actividades realizadas:

- ❖ Experimentación con múltiples arquitecturas
- ❖ Implementación de técnicas de transfer learning
- ❖ Optimización de hiperparámetros
- ❖ Evaluación comparativa de modelos
- ❖ Refinamiento iterativo
- ❖ Validar el objetivo de minería de datos

5. Evaluación

- ❖ Evaluar los resultados obtenidos
- ❖ Obtener los modelos aprobados

- ❖ Validar el objetivo de negocio
- ❖ Revisión de procesos
- ❖ Analizar pasos siguientes y tomar una decisión

6. Entrega

- ❖ Plan de Entrega
- ❖ Plan de Mantenimiento
- ❖ Reportes Finales
- ❖ Presentación Final
- ❖ Entregar los resultados

5.2 Costos asociados al proyecto

Considerando las fases del proceso que se describieron previamente esto fue lo que el costo el proyecto:

Fase	Costo
Comprensión del Negocio	29 horas
Entendimiento de los Datos	8 horas
Preparación de los Datos	64.6 horas
Modelado	122.5 horas
Evaluación	18 horas
Entrega	60.2 horas
Total	302.3

5.3 Desviaciones del plan original.

Durante la fase de modelado a pesar de las multiples arquitecturas utilizadas y los ajustes realizados a los parámetros de los modelos, no logramos obtener resultados

satisfactorios. Por lo que fue necesario buscar otro enfoque para tratar de obtener un desempeño decente. Como solución, se cambió el etiquetado del dataset, pasando de ser clasificación a segmentación, utilizando Bounding - Boxes para marcar la ubicación exacta de cada vaca en la imagen por medio de coordenadas y de esta forma contar la cantidad de vacas en la imagen. Con esto en lugar de tener un modelo diurno y otro nocturno, hicimos uno general para todas las condiciones de iluminación.

5.4 Planes de implementación:

El Socio Formador podrá ejecutar la imagen de Docker provista en cualquier computadora que posea un procesador ARM64, de esta manera la implementación en el CAETEC consistirá en instalar Docker en la Raspberry PI del cliente y ejecutar la imagen. Teniendo la base de datos de S3 y la computadora conectada a internet con la cámara web, el sistema empezará a clasificar y a subir las imágenes en automático.

Plan de Entrega:

<https://github.com/salgue441/cow-project/blob/main/docs/Plan%20de%20Entrega.pdf>

Plan de Mantenimiento:

<https://github.com/salgue441/cow-project/blob/main/docs/Plan%20de%20Monitoreo%20y%20Mantenimiento.pdf>

Manual de Despliegue:

<https://github.com/salgue441/cow-project/blob/main/docs/Manual%20de%20Despliegue%20-%20YOLO%20VI.pdf>

5.5 Recomendaciones para el futuro:

Para mejorar el rendimiento del modelo en el tiempo nocturno, se recomienda instalar un mejor sistema de iluminación que esté activo durante la noche, permitiendo que la imagen se vea más nítida y clara, y a simple vista se puedan encontrar fácilmente a las vacas, sin importar sus rasgos físicos.